Hoja de Ruta: Transformación del Agente de Reservas a Nivel Competitivo

Este documento detalla los pasos técnicos y estratégicos para convertir el prototipo actual en un producto comercial escalable, multicanal y de bajo coste operativo.

Fase 1: Cimentación y Soberanía Tecnológica (Mes 1)

El objetivo es eliminar la dependencia de APIs externas para el "cerebro" del agente y preparar el sistema para instalaciones masivas.

1.1. Optimización de Ollama Local

- **Modelo:** Migrar a **Llama 3.1 8B** o **Mistral Nemo 12B**. Estos modelos tienen el equilibrio perfecto entre velocidad y capacidad de seguir el formato JSON del agente.
- **Cuantización:** Usar versiones `Q4_K_M` para reducir el consumo de VRAM, permitiendo ejecutar el agente en servidores VPS económicos (8GB-16GB RAM).
- **Seguridad:** Implementar un proxy inverso (Nginx) con autenticación básica delante de Ollama para evitar accesos no autorizados.

1.2. Dockerización y Despliegue en un Clic

- Crear un `docker-compose.yml` que incluya:
  - **Backend:** FastAPI.
  - **Frontend:** React (servido por Nginx).
  - **Base de Datos:** Migrar de SQLite a **PostgreSQL** (necesario para entornos multi-empresa).
  - **IA:** Contenedor de Ollama pre-configurado.

- **Beneficio:** Facilita la instalación en cualquier servidor Linux en menos de 5 minutos.

Fase 2: Expansión Multicanal - WhatsApp (Mes 2)

Integrar el canal de comunicación más utilizado por los clientes sin pagar las altas tasas de la API oficial de Meta.

2.1. Integración con Evolution API (Open Source)

- **Por qué:** Permite conectar cualquier número de WhatsApp mediante escaneo de QR (WhatsApp Web), eliminando costes por mensaje.
- **Desarrollo:**
  - Configurar un **Webhook** en FastAPI que escuche los eventos `MESSAGES_UPSERT` de Evolution API.
  - Mapear el número de teléfono del remitente con el `session_id` de la base de datos para mantener el contexto.
  - Enviar las respuestas del LLM de vuelta a través del endpoint `/message/sendText` de Evolution API.

2.2. Gestión de Media y Adjuntos

- Implementar lógica para que el agente pueda recibir imágenes (ej. comprobantes de pago o fotos del evento) y guardarlas en el servidor asociadas a la reserva.

Fase 3: Integración de Voz y Telefonía (Mes 3)

Convertir el agente de texto en un asistente telefónico capaz de responder llamadas y agendar citas en tiempo real.

3.1. Conexión con Vapi.ai o Retell AI

- **Arquitectura:** Usar el Backend de FastAPI como un **Custom LLM URL**.

- **Flujo:**
    1. Vapi recibe la llamada -> Convierte voz a texto (STT).
    2. Envía el texto a tu Backend.
    3. Tu Backend procesa con Ollama y devuelve el JSON de respuesta.
    4. Vapi convierte el texto a voz (TTS) y responde al cliente.
- **Coste:** Solo se paga por minuto de uso de voz, manteniendo el procesamiento de IA gratuito en tu servidor.

3.2. Lógica de Interrupción y Latencia

- Optimizar el Backend para responder en <500ms (streaming de tokens) para que la conversación telefónica sea natural.

Fase 4: Panel de Control y Monetización (Mes 4)

Convertir el código en un producto SaaS (Software as a Service) que puedas vender a múltiples negocios.

4.1. Dashboard para el Dueño del Negocio

- Interfaz para:
    - Configurar horarios y festivos.
    - Personalizar el “Prompt de Sistema” (personalidad del agente).
    - Ver y editar reservas en un calendario visual.
    - Configurar las credenciales de WhatsApp y Correo.

4.2. Sistema Multi-Tenant

- Modificar la base de datos para que un solo servidor pueda gestionar múltiples negocios de forma aislada, permitiéndote cobrar una suscripción mensual a cada uno.

Resumen de Tecnologías Sugeridas

Función	Tecnología Recomendada	Coste Estimado
Cerebro IA	Ollama (Llama 3.1)	$0 (Local)
WhatsApp	Evolution API	$0 (Open Source)
Telefonía	Vapi.ai + Twilio	~$0.05 / min
Base de Datos	PostgreSQL	$0
Servidor	VPS Linux (Hetzner/DigitalOcean)	10—20 / mes

Documento de Hoja de Ruta - Preparado por Manus para Agente de Reservas Competitivo.